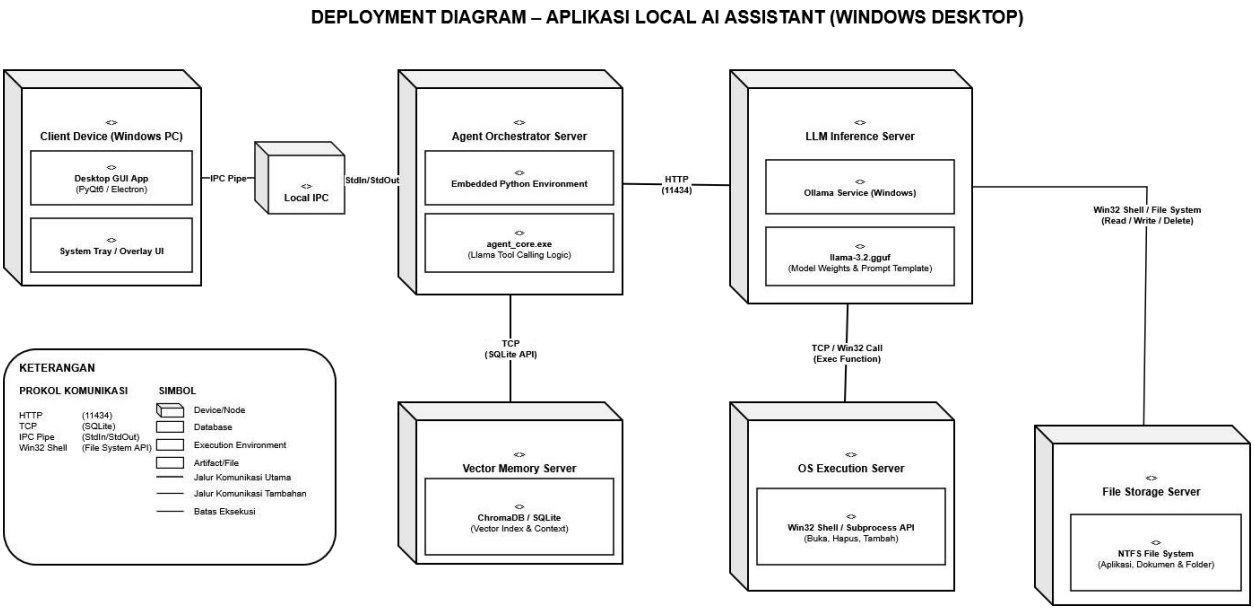
DEPLOYMENT DIAGRAM



Dokumen ini merinci arsitektur *deployment* perangkat lunak Local AI Assistant berbasis Desktop Windows. Sistem ini dirancang untuk berjalan secara sepenuhnya lokal (*local-first / edge AI*) di komputer pengguna tanpa ketergantungan pada server *cloud* eksternal. Dengan memanfaatkan model bahasa besar (Llama 3.2) dan mekanisme *Tool Calling*, asisten ini memiliki kemampuan untuk mengeksekusi perintah sistem operasi nyata secara aman, meliputi membuka aplikasi, membuat/menambahkan berkas, serta menghapus file/folder secara otomatis berdasarkan instruksi pengguna.

1. KOMPONEN DAN NODE DALAM DEPLOYMENT DIAGRAM

Berdasarkan diagram arsitektur sistem, berikut adalah rincian komponen yang terbagi ke dalam berbagai *Node*, *Execution Environment*, *Database*, dan *Artifact*:

A. Client Device (Windows PC) – <<device>>

Perangkat keras fisik milik pengguna yang menjalankan antarmuka utama aplikasi.

- Desktop GUI App (PyQt6 / Electron) – <<executionEnvironment>>: Antarmuka grafis utama bagi pengguna untuk berinteraksi, mengetik perintah teks, atau menerima respons dari AI.
- System Tray / Overlay UI – <<executionEnvironment>>: Modul latar belakang yang menjaga agar aplikasi tetap aktif dan mudah diakses melalui *system tray* Windows.

B. Local IPC – <<node>>

- IPC Pipe & StdIn/StdOut: Jalur komunikasi perantara (*inter-process communication*) yang menghubungkan lapisan antarmuka grafis dengan proses backend agen secara aman di memori lokal.

C. Agent Orchestrator Server – <<node>>

Pusat kendali logika aplikasi dan perutean (*router*) instruksi.

- Embedded Python Environment – <<executionEnvironment>>: Lingkungan *runtime* Python terisolasi yang dibundel langsung ke dalam paket instalasi aplikasi.
- agent_core.exe – <<artifact>>: Berkas biner (*executable*) utama yang menjalankan kerangka kerja agen, menangani logika pemanggilan alat (*tool calling*), serta mengelola alur percakapan.

D. LLM Inference Server – <<node>>

Server lokal yang bertugas memproses penalaran kecerdasan buatan.

- Ollama Service (Windows) – <<executionEnvironment>>: Layanan latar belakang Windows yang mengatur pemanggilan model inferensi AI.
- llama-3.2.gguf – <<artifact>>: Berkas bobot model AI terkuantisasi (Llama 3.2) beserta templat *prompt* yang berjalan dengan akselerasi perangkat keras lokal (CPU/GPU).

E. Vector Memory Server – <<node>>

Penyimpanan memori jangka panjang dan indeks dokumen (*Retrieval-Augmented Generation / RAG*).

- ChromaDB / SQLite – <<database>>: Pustaka basis data vektor lokal yang menyimpan indeks dokumen dan riwayat percakapan agar AI memiliki memori kontekstual.

F. OS Execution Server – <<node>>

Lapisan yang menjembatani instruksi AI dengan sistem operasi komputer host.

- Win32 Shell / Subprocess API – <<executionEnvironment>>: Modul pustaka yang menerjemahkan keputusan *tool call* dari AI menjadi perintah operasional sistem (membuka, menghapus, atau menambah berkas/aplikasi).

G. File Storage Server – <<node>>

Penyimpanan permanen pada perangkat keras lokal.

- NTFS File System – <<artifact>>: Sistem berkas standar Windows tempat aplikasi, dokumen, dan direktori pengguna disimpan.

3. MEKANISME DAN PROTOKOL KOMUNIKASI

Komunikasi antar komponen dalam arsitektur ini menggunakan protokol lokal yang cepat dan aman:

1. GUI ke Local IPC (IPC Pipe / StdIn/StdOut): Pengiriman perintah dari antarmuka pengguna ke proses agen backend.
2. Agent Server ke LLM Inference (HTTP (11434)): Pengiriman prompt dan instruksi terstruktur ke *Ollama Service* melalui REST API lokal pada port 11434.
3. Agent Server ke Vector Memory (TCP / SQLite API): Pengambilan konteks memori dan data vektor secara lokal.
4. LLM Inference ke OS Execution (TCP / Win32 Call): Eksekusi fungsi sistem setelah model memberikan keputusan *tool calling*.
5. OS Execution ke File Storage (Win32 Shell / File System): Operasi baca, tulis, atau hapus berkas (*Read / Write / Delete*) secara langsung pada sistem berkas NTFS.